

1. 使用 AI 帮助完成，先利用 AI 分析论文，了解 SGLang 是什么，有什么作用，怎么用和它的功能，以及先理解 KV, RadixCache, vLLM, PagedAttention 这些概念，再开始配置环境，配置环境的过程中，遇到问题比方说启动 SGLang 的时候报错说缺少 nvcc 编译，后来通过询问 AI 安装 CUDA Toolkit 之后重新启动，就跑通了，再比如说 Ubuntu 没有 Windows 的网络代理没办法下载 Mooncake，询问 AI 后是在浏览器里面下载再通过 Windows 和 Ubuntu 文件互通复制过去的
2. 配置环境最难，要下载很多东西，还要不断调试下载好的东西互相能否识别，能不能完成请求。
3. 第一需要明确问题，弄清楚究竟在研究什么，做什么实验，要得到怎么样的结论，第二明确问题后找到相关的论文和文献（此次已经给了我们参考文献），第三获取论文中的信息，从理解其中的基本概念开始，掌握基本概念后最大可能理解此篇论文的研究成果，研究方法，和研究成果和自己的科研的交叉点并运用。