

用户发送请求

SGLang接收
请求

整理请求内容并转
换成模型可以处理
的token

这一步是SGLang调用的
Qwen模型配套的分词器完
成的

检查RadixCache: 有没有之前处
理过相同的开头

重点

RadixCache 是 SGLang 自
带的缓存管理机制 (见论
文)

有可复用
内容

复用缓存
中的 KV
内容

没有可复用
内容

计算输入内
容并生成
KV 内容

输入对应的
KV已就绪

模型逐步生成
后续 token

将生成内容整
理成回答

SGLang 返回
结果给用户

保留可复用的
前缀缓存, 供
后续请求使用

不会无限的保留旧内容, 当空间紧张
的时候, 会删除一部分旧内容为新的请求
腾空间