


(1) 简述下你是如何完成第二次挑战的:

任务一: 先通过 AI 理清楚这次挑战的要求, 需要达到怎么样的实验目标, 然后在已经搭建好的实验环境中, 运行 SGLang, 清空可复用的缓存, 避免实验被干扰, 然后在 Mooncake 记录里面挑出适合饰演的长度, 准备好两组输入, 进行预热请求后开启第一组共享前缀实验, 记录实验数据, 清空缓存后, 开启第一组不共享前缀实验, 记录数据, 清空缓存, 再重复一组, 然后得到两组实验结果, 将实验结果发给 AI, 制成表格, 最后结合公式解释实验结果并验证了 SGLang 中 RadixCache 前缀复用减少了重复处理的输入 token

任务二:

跟踪 /generate 请求流程、查 v0.5.14 源码中的关键函数和文件, 先做一个简单的流程图



再将流程图喂给 AI, 做出一份更加精美, 简洁, 可读性更强的流程图。

(2) 你觉得哪部分工作最困难, 你是如何克服这个困难的:

这次挑战最难的是理解, 整理并归纳实验数据, 通过实验数据结合公式解释实验结果, 因为这部分过程中需要查一些专业术语的意思, 以及需要用尽量组织专业的术语表达实验的结果, 还有一个难点就是理解掌握虚拟机里常见的命令行, 克服的方法就是询问 AI 每个概念的含义, 将自己的理解喂给 AI, 让他帮忙纠错自己的理解有什么错误的地方。

(3) 你觉得类似的从 0 到 1 的科研工作, 需要包含哪些方面的研究, 对你今后的科研工作有什么启发:

这次实验的启发是, 做对照组实验需要控制好比较条件, 不能忘记清空前一组实验留下来的 KV 缓存, 以免影响下一组实验 (也就是控制变量), 其他的和上一次挑战一样, 查资料, 理解概念, 理清实验目的, 实验原理, 记录数据, 重复实验, 分析实验结果, 将实验结果和已有的论文或者公式相结合, 看实验结果是否合理。